


Quando a IA entra no fluxo de entrega

Resposta deixa de ser a unidade de entrega

RESPONDE


texto entra → texto sai




O trabalho termina na resposta.
Nenhum arquivo, comando ou efeito no ambiente.

TRABALHA NO AMBIENTE

direção humana → ações → evidência



A TRAVA DO ARGUMENTO



Mais capacidade ≠ delegação irrestrita

maior raio de ação → maior necessidade de controle

Responsabilidade continua humana

○ o que deve ser feito · qual risco é aceitável

● que evidência autoriza a conclusão

Do chat à autonomia – a superfície é só o começo


RAIO DE AÇÃO CRESCENTE

Cada estágio amplia a unidade de entrega – e também a responsabilidade ao redor dela.

01

Assistente conversacional

Unidade de entrega: resposta



CHAMADA INDIVIDUAL


texto entra → texto sai

Limite: o efeito termina no texto.

02

Agente de codificação

Unidade de entrega: trabalho no ambiente



SEQUÊNCIA NO REPOSITÓRIO

lê repositório → escreve arquivo → executa comando → observa resultado


Limite: autonomia dentro da direção recebida.

03

Sistema agêntico

Unidade de entrega: percurso até um critério verificável

Direção humana define o objetivo



PERCURSO ENTRE CHAMADAS

ação 1 → estado preservado → ação 2
→ efeito produzido → critério atendido

Estado e efeitos sobrevivem à chamada individual.

autonomia ↑


risco ↑

controle necessário ↑

Mais capacidade não significa delegação irrestrita.

Sistemas agênticos abrem um novo território

O agente não é apenas uma chamada ao modelo – é um workload com estado, dependências e efeitos




O mercado já está nomeando o novo trabalho


Três títulos diferentes apontam para o mesmo centro de gravidade

OS NOMES QUE APARECEM

O QUE O TRABALHO PASSA A POSSUIR




O PERCURSO DE RESPONSABILIDADE – DO CONTEXTO AO APRENDIZADO REUTILIZÁVEL



evidência de recomposição do trabalho – nunca promessa de cargo

Quando o código fica barato, o gargalo muda de lugar

O GARGALO MUDOU DE LUGAR →



IA aumenta o volume de mudanças → Cloud/DevOps absorve decisões, risco e operação → papéis e responsabilidades mudam


de habilitar deploys → governar o fluxo inteiro até produção e operação

ownership do problema inteiro

Da tarefa isolada à operação responsável


Quatro estágios percorríveis – autonomia, risco e responsabilidade crescem juntos

A IA barateia execução.
Julgamento continua caro.



Quatro engenharias sustentam a entrega

Um único fluxo, atravessado por quatro perguntas encaixadas – não quatro caixas independentes




Prompt está dentro do contexto · Contexto é administrado pelo harness · Loop acontece dentro do harness

INSTRUÇÃO → MATERIAL DISPONÍVEL → AMBIENTE DE EXECUÇÃO → CICLO → ENTREGA

Engenharia de prompt – dirigir a chamada

A instrução muda o espaço de decisão – não cria capacidades ao redor do modelo



Zero-shot × few-shot – o padrão tem custo de entrada

Experimento controlado: mesma tarefa · mesmo modelo · mesmo incidente

INCIDENTE CRU · SQUAD COBRANÇA · 2026-08-19

ack timeout 5 min → 30s · processamento ≈ 90s
reentrega em loop · 1.284 cobranças duplicadas

ÚNICA VARIÁVEL
presença dos
dois exemplos

ZERO-SHOT · sem exemplos

papel + pedido
"Documento como post-mortem no padrão da equipe"

MESMO MODELO
executa a tarefa

ADERÊNCIA OBSERVADA À RÉGUA

- ✓ post-mortem competente
- ✓ seções razoáveis
- ? seções e ordem específicas do time
- ? ação no formato esperado

FEW-SHOT · com 2 exemplos

REFERÊNCIAS DE FORMATO

EXEMPLO 1
certificado TLS expirado
25 min · P2 · @ana.sre
2 ações com dono + data

EXEMPLO 2 · mais completo, por último
LOG_LEVEL=debug → disco cheio
1h10 · P1 · @bruno.dev
3 ações · timeline longa · 2 serviços

MESMO MODELO
infere o padrão

- ✓ Data · Duração · Severidade · Responsável
 - ✓ Resumo · Timeline · Causa raiz · Ações corretivas
- AMOSTRA REAL DO PADRÃO
- [] Criar alerta de disco do nó acima de 80% - @ana.sre - até 2026-07-18

RÉGUA COMPARTILHADA DE ADERÊNCIA

GENÉRICO

zero-shot

PADRÃO DO TIME

few-shot

CUSTO DE ENTRADA


zero-shot · prompt-base

mais exemplos → mais tokens de entrada · os exemplos voltam no prompt a cada chamada

few-shot · prompt-base + exemplo 1 + exemplo 2


Engenharia de contexto – fornecer material para decidir

A decisão só pode usar o material que coube na janela desta chamada




Chain of Thought – transformar diagnóstico em percurso

Passos intermediários encadeiam o problema à conclusão.



ANATOMIA DA CADEIA · ORDEM + DEPENDÊNCIA MUDAM O ESTADO



DUAS FORMAS DE INDUZIR	QUANDO AGREGA	QUANDO TENDE A NÃO COMPRAR VALOR	BENEFÍCIOS	DESVANTAGENS
	• múltiplas relações • cálculo • diagnóstico • planejamento	• resposta simples • formatação direta	decomposição consistência do percurso apresentado inspeção / revisão incerteza explícita	• mais tokens • mais latência • cadeia plausível, porém errada • percurso desnecessário ou limitado

SAÍDA INSPECIONÁVEL
passos apresentados ≠ acesso garantido ao raciocínio privado do modelo

Janela de contexto – a memória de trabalho da chamada

Como a RAM: só o que está carregado agora participa do processamento.

MÓDULO DE MEMÓRIA DE TRABALHO · USO MOMENTÂNEO

● uso imediato

○ capacidade limitada

MATERIAL DISPONÍVEL

existe fora da janela

- instruções
- pedido atual
- histórico
- arquivos
- resultados de tools

carregar para esta chamada →

ENG. DE CONTEXTO decide o que carregar

excesso / ruído fica fora

JANELA DE CONTEXTO

memória de trabalho desta chamada

PROMPT / INSTRUÇÕES · como executar o trabalho

PEDIDO ATUAL · o objetivo desta chamada

HISTÓRICO SELECIONADO · somente o que importa agora

DADOS E RESULTADOS ÚTEIS · evidência disponível

TOKENS DISPONÍVEIS

ocupado pelo contexto carregado

espaço livre

lê somente os slots carregados

MODELO processa agora

resposta / próxima ação

● conteúdo temporário


○ reconstruída na próxima chamada

O modelo trabalha com o que está carregado agora – não com tudo que existe.

Analogia de comportamento; não é equivalência física com RAM.

Dados sob demanda – carregar só o necessário

Como um HD: muito pode persistir; só a parte necessária vai para a memória de trabalho.




Memória longa guarda muito. Engenharia de contexto carrega o mínimo suficiente, na hora necessária.

Analogia de comportamento; arquivos e contexto não são hardware.


Harness Engineering – o sistema que conecta, limita e verifica

Capacidades e controles persistentes governam o trabalho recorrente do agente


NÍVEL 1 · O AGENTE DENTRO DO HARNESS



NÍVEL 2 · O MINI FLUXO GOVERNADO



NÍVEL 3 · QUANDO FALTAM PEÇAS PERSISTENTES



A CLI prova que algo executou. O harness transforma padrões e limites em condições repetíveis de confiança.

Loop Engineering – quem fecha o ciclo?


Três escalas de execução; quatro responsabilidades que não somem com a automação

INTERAÇÃO HUMANA ↓ AUTONOMIA DA IA ↑

○ trigger humano - - - ciclo automatizado


1 · ReAct

um microciclo dentro da execução




2 · Inner Loop

converge uma entrega até um critério local



3 · Outer Loop

coordena tarefas locais até a entrega global




RESPONSABILIDADE	ReAct mecanismo local	Inner Loop convergência de uma tarefa local	Outer Loop IA coordena vários Inner Loops para concluir a tarefa maior
quem observa	agente lê a observação	agente + verificador local	humano delega o objetivo global e avalia a entrega
quem leva a evidência	retorno da ferramenta	harness reenvia erro e estado	IA integra resultados; harness preserva plan e decisões
quem decide a próxima ação	agente atualiza o plano	humano inicia; agente decide as repetições	IA decide decomposição, coordenação e próximas subtarefas
quem declara terminado	não define sozinho a entrega	harness aplica o critério definido pelo humano	critérios locais fecham loops; conclusão volta ao humano

Fechar um passo, convergir uma tarefa e coordenar uma entrega maior são decisões em escalas diferentes.

Harness nos loops – guias orientam, sensores devolvem evidência

O loop só corrige e para com autonomia quando recebe direção antes da ação e evidência depois dela.



GUIAS reduzem erro antes da ação + SENSORES tornam o resultado observável
+ LOOPS usam evidência para corrigir e parar = mais autonomia com critérios observáveis